

基于机器学习的多维信号处理方法研究

赵家乐

院（系）： 物理学院 专 业： 应用物理系
学 号： 1181100101 指导教师： 张子静

2022年6月6日

哈爾濱工業大學

畢業設計（論文）

題 目 基於機器學習的多維
信號處理方法研究

專 業 應用物理系

學 號 1181100101

學 生 趙家樂

指 導 教 師 張子靜

答 辯 日 期 2022 年 6 月 6 日

摘 要

近年来，人工智能领域迎来了飞速的发展，取得了一系列突破性进展。人工智能也被应用于各个领域，比如：计算机视觉、自然语言处理、语音处理等等。由于机器学习的强大威力，也涌现出了许多机器学习应用于物理学的研究。

本文主要贡献包括利用了三种不同的神经网络，其中独立设计了一种神经网络，应用到不同维度的光学信号处理。分别利用时序卷积神经网络(TCN)处理一维光子计数雷达时序信息，利用 U-Net 处理二维涡旋光角谱信号处理，利用本文设计的卷积注意力模块与张量积融合同时处理涡旋光角谱与光强信号。

本文首先介绍了涡旋光探测、机器学习辅助涡旋光模式识别与光子计数雷达研究现状及分析。接着介绍本文的研究成果：首先，利用了 TCN 处理光子计数雷达时序信号时，仅仅需要 2-5 个样本数据便可以在强噪声下实现很高精度的信号处理。其次，介绍了涡旋光基本知识与涡旋光角谱原理，利用 U-Net 处理角谱信号，可以更精细的识别不同阶涡旋光能量占比。随后，介绍了涡旋光穿过大气湍流的仿真与利用卷积注意力模块与张量融合机制可以更好地实现涡旋光模式识别，相对于以往的研究实现大幅度准确率提高、神经网络复杂度降低、所需训练集减小等等效果。

关键词：人工智能，机器学习，光子计数雷达；涡旋光；角谱

Abstract

Recently, there has been many exciting breakthrough in Artificial Intelligence. Artificial Intelligence has been applied in a number of areas, such as computer vision, natural language process, speech process, etc. Machine learning has also been extensively applied in physics in recent years.

In this paper, three different neural networks are applied in processing different dimensions of optics signals. Firstly, Temporal convolutional network(TCN) is used to process one dimensional photon counting radar signal. Secondly, U-Net is used to process two dimensional angular spectrum signal. At last, inspired by multimodal learning, multidimensional feature fusion convolutional neural network (MFFCNN) is originally proposed in this paper to process signals with higher dimension. In order to extract features more effectively, convolutional block attention module (CBAM) is used in MFFCNN. Also tensor fusion is used to fuse features in different dimensions more effectively.

This paper first introduced the background of detection of vortex beam, pattern recognition of vortex beam and photon counting radar. Then, this paper makes use of TCN to process photon counting radar. It turns out TCN can locate signal even in strong background noise accurately. Next, U-Net is applied in angular spectrum signal process, which realized super-high accurate recognition of energy distribution in different modes. At the same time, basic theory of vortex beam and angular spectrum is introduced. Next, MFFCNN is applied in pattern recognition of vortex beam. Meanwhile, this paper also discussed simulation of propagation of vortex beam in atmospheric turbulence in detail.

Keywords: Artificial Intelligence, Machine Learning, Photon Counting Radar, Vortex Beam, Angular Spectrum

目 录

摘 要	I
Abstract	II
 第 1 章 绪论	 1
1.1 研究现状.....	1
1.1.1 涡旋光探测研究现状.....	1
1.1.2 机器学习辅助涡旋光模式识别研究现状	2
1.1.3 光子计数激光探测研究现状	2
1.1.4 研究现状分析	3
1.2 论文主要内容	4
第 2 章 一维光子计数激光探测信号处理方法研究	5
2.1 光子计数激光探测时序信号	5
2.2 时序卷积神经网络.....	5
2.3 TCN 处理过程及结果	7
2.4 本章小结.....	8
第 3 章 二维角谱图像信号信号处理方法研究	10
3.1 涡旋光背景知识	10
3.2 涡旋光角谱	11
3.3 U-Net 网络架构	14
3.4 U-Net 处理过程及结果	15
3.5 本章小结.....	16
第 4 章 多维光强角谱图像融合信号处理方法研究	17
4.1 涡旋光通过大气湍流仿真	17
4.2 多维特征融合神经网络.....	18
4.3 多维特征融合神经网络处理过程及结果	20
4.3.1 距离限制	20
4.3.2 正负拓扑核数限制	21
4.3.3 湍流强度	22
4.3.4 训练集大小	23

4.3.5 计算复杂度	24
4.4 本章小结.....	24
结 论	25
参考文献	26
哈尔滨工业大学本科毕业设计（论文）原创性声明	30
致 谢	31

第 1 章 绪论

早在 16 世纪，开普勒就意识到光应该是有动量的，他认为彗星的尾巴朝向远离太阳的方向可以证明这件事情^[1]。虽然光的所有动量能量的特性都被 Maxwell 方程组包含，但是直到 1909 年，Poynting 用力学类比阐述，圆偏振光束应该包含光子自旋产生的角动量。除了光子自旋的内禀属性产生的角动量，达尔文（著名生物学家的孙子）指出，为了满足原子高阶能级跃迁的角动量守恒，要求每个光子光子具备数个 \hbar 的角动量值。高于 $1\hbar$ 的角动量被称为轨道角动量。之后的数十年，这种跃迁现象被认为只是罕见的现象，并没有引起广泛注意。

直到 1992 年，L.Allen 意识到，带有螺旋相位因子 $\exp(il\phi)$ 的光束每个光子带有轨道角动量 $l\hbar$ ^[2]。之后带有轨道角动量的光被广泛应用于光场操控^[3]、光学成像^[4]、光通信^[5]。由于 l 可以取任意整数，涡旋光有着巨大的储存信息的能力，也暗示着带有轨道角动量的涡旋光在光通信领域的巨大潜力。

光子计数激光探测探测远程目标时，存在着背景噪声导致探测远程目标效果下降的问题。如今的降噪手段，对于弱信号强噪声情景鲁棒性不够好。受益于高精度的光子计数灵敏度和皮秒级别的时间灵敏度，配有盖革模式雪崩光电二极管的计数雷达已经被广泛应用于远程高分辨率测距与 3D 成像^[6]。测距误差是最重要的评价光子计数激光探测的参数。导致测距误差最主要的因素是无法避免噪声，比如太阳光。理论分析表明随着噪声的增大，测距误差也变大^[7]。

虽然物理研究的是万物演化的规律，但是物理规律未必都存在优雅的解析解，虽然我们总希望物理规律是优雅的，但总有一些比较繁琐的部分，而这一部分可能物理意义并不清晰相对显得并不重要，这时候如果把这些任务交给机器学习完成，我们只需要完成物理意义比较明显的比较优雅的部分就可以，就会比较轻松。机器学习可以看作是寻找一个从输入到输出的函数或者映射的一个过程。通过转化问题我们可以利用机器学习解决物理研究中的繁琐的问题。

1.1 研究现状

1.1.1 涡旋光探测研究现状

光的轨道角动量的测量近些年也有了快速的发展。一开始人们利用生成 LG

光的逆过程来判断 LG 光的模式^[8]，比如，利用叉形全息图等方法来移除螺旋相位结构，然而这种方法的成功率受 $1/N$ 的限制，其中 N 为过程所涉及的模式数。后来，人们利用更加巧妙的方法来做模式识别，能够做到识别多种模式光的叠加态。比如，Leach 等人提出一种基于 March-Zehdner 干涉仪并每一个臂加上一个棱镜的检测方法^[9]，理论上该方法的效率为 100%，然而这种方法分离 N 种模式便需要 $N - 1$ 套干涉仪，需要比较复杂的系统。也有一些尝试使用经过一相位为 $t(\phi) = \exp(i2\pi\phi/P)$ 的相位光栅后直接观察形成光斑判断涡旋光阶数。虽然光栅测量方法光学系统简单，但是其光斑结果不够直观，也不能很好地判断叠加态各阶能量占比。

最近 Berkhout et al 发现了一种非常成功的分离涡旋光模式的方法^[10]，利用坐标变换把螺旋的相位结构映射为倾斜的平面波的相位结构，并且利用透镜聚焦来做到分离不同拓扑核数的涡旋光模式。本课题便是要利用这种方法来取得角谱的信息来高分辨率地识别通过湍流的涡旋光的模式。并实现对多阶各阶能量占比的高分辨率识别。

1.1.2 机器学习辅助涡旋光模式识别研究现状

深度学习在近些年了来发展迅速，在很多领域都展现出了强大的威力。近些年来也有许多研究者把深度学习应用到了 LG 光的识别上。早在 2016 年便有 E.M.Knutson 等人把卷积神经网络应用到了 LG 光模式的识别上^[11]。近些年又有许多研究者不断改进深度学习识别 LG 光的方法。比如，2019 年，深圳大学的 Junmin Liu 等人^[12]，利用深度学习根据光强图像预测湍流对光束的影响，并补偿光强图像使得识别准确率上升；2018 年，北京邮电大学 Jin Li 等人^[13]，发现卷积神经网络识别正负相同大小轨道角动量的 LG 光叠加时正确率有显著提升；2019 年，哈尔滨工业大学 Shutian Liu 与合肥工业大学 Zikun Wang 提出了一种计算量很小，计算速度很快的识别 LG 光的神经网络^[14]；2019 年，国防科技大学 Zhanwei Liu 等利用深度学习对非整数阶涡旋光模式进行识别实现了超高分辨率识别涡旋光阶数，对阶数相差 0.01 的涡旋光也能很好地识别^[15]。

1.1.3 光子计数激光探测研究现状

如今已有很多对于光子计数激光探测的降噪手段。在测距应用中，一个常用的手段是迭代西格玛乘数过滤器。它切断信号峰附近区域内的光子计数直方图，宽度为发射脉冲标准偏差的倍数。它的可靠性非常依赖回波信号峰值位置的准确性。另外一种常用的手段是设置一个阈值来屡遭。利用多脉冲的相关处

理算法来区分噪声以改善检测 Gm-APD 检测器的概率。

已经提出了几种用于光子计数激光探测的抗噪声方法。在测距在应用程序中,经常使用的方法是,2015 年提出的迭代西格玛乘法器滤波器。它切断信号峰附近区域内的光子计数直方图,宽度为发射脉冲标准偏差的乘数^[16]。它的可靠性非常依赖回波信号峰值位置的准确性。另一种广泛使用的方法是设置一个阈值来过滤噪声。2013 年,有研究者对多脉冲的重合处理提出了一种阈值算法来区分噪声以改善检测 Gm-APD 检测器的概率^[17]。2013 年,张子静老师等提出相邻阈值方法来过滤噪声,并在噪声条件下获得目标的深度图像^[18]。直接阈值法方便,可以在以下情况下获得良好的性能信噪比 (SNR) 相对较高,但当 SNR 降低时,很可能将噪声计数误判为信号计数。在 3D 成像应用中,一些抗噪在信号提取之前也提出了方法。基于集群的假设在光子计数直方图中,由于信号,2017 年,Joshua Rapp 等人提出了一个噪音删失方法^[19]和 2021 年, Hua 等人提出了第一个信号光子单元方法^[20]来区分信号计数以获得更清晰的光子计数数据。这样的方法是适用于低通量场景,但在高背景场景中不满足假设。提到的抗噪声方法可以归类为基于直方图的方法,但它们受背景噪音的影响很大。

处理噪声更有效的方法是基于相关性的方法,即称为匹配滤波器,它执行系统响应之间的互相关用光子计数直方图提取信号。2015 年,奥罗拉等使用了匹配的在高散射环境中抑制背景噪声的滤波方法,以及估计水下目标的深度图像^[21]。2010 年,马库斯等人执行匹配对光子计数直方图进行滤波以改善信号的特性用于确定回波峰值的位置和幅度。匹配的过滤器工作在比基于直方图的方法更低的 SNR,但是,在弱信号和强噪声条件,它给出了几个极值,信号峰值的位置很难确定^[22]。此外,当回波波形受检测场景影响时,需要提前测量实时场景的脉冲响应,但它是在强大的背景下难以实现。熵是一个重要的工具定量评估随机事件的不确定性,最近很多技术使用熵来提高检测性能已经在雷达、超宽带测距和定位、模糊聚类和密码系统^[23]。为了光子计数激光探测的测距过程,噪声是一个平稳的随机过程并且信号是一个非平稳的随机过程,这意味着噪声的波动光子事件 (PE) 是完全随机的,信号 PE 的事件与激光脉冲有关,即噪声事件之间波动的不确定性要高得多。2019 年同组的黄名维师兄利用熵来进行对光子计数激光探测信号处理^[23]。

1.1.4 研究现状分析

现在的利用深度学习识别 LG 光模式的方法大多有很强的限制。比如,第一,只能识别传输一定距离的 LG 光的模式,即当距离变化时需要重新建立训

练集重新训练神经网络；第二，只能有效地识别拓扑核数为正数的 LG 光，即分辨例如拓扑核数为-1 与 1 的 LG 光准确率并不理想，第三，以往研究涡旋光模式识别准确率有待提升，使得可装载的信息容量大大减小。事实上出现这些问题的根本原因在于光场是由光强与相位共同描述，而以往研究仅仅利用到光强信息，并没有利用相位信息。恰恰对于涡旋光，其螺旋的相位结构赋予涡旋光轨道角动量，相位应是涡旋光模式识别更加根本的特征，以往研究的卷积神经网络无法抽取相位特征输入全连接层进行分类，于是便出现了上述问题。同时目前也缺乏对涡旋光叠加态不同阶能量占比的识别，目前研究主要关注单阶涡旋光的模式识别。

对于光子计数激光探测信号处理基于直方图的方法和基于相关的方法都缺乏在弱信号但强背景噪声的情况下具有足够的鲁棒性，例如白天远距离探测场景，测距误差较差。因此，需要建立一个更强大的抗噪技术。

1.2 论文主要内容

本文对一维的光子计数激光探测时序信号，二维角谱图像信号，高维即同时利用光强与角谱图像信号分别设计并实现了适当的神经网络进行信号处理。

第一章是本文绪论，介绍了国内外涡旋光探测研究现状、机器学习辅助涡旋光模式识别研究现状、光子计数雷达研究现状以及现状分析。

第二章是对一维时序信号处理的神经网络设计，本文使用了时序卷积神经网络对一维光子计数激光探测信号处理，实现了对信号的精准定位。

第三章是对二维角谱信号处理的神经网络设计，首先介绍角谱概念以及角谱生成方法，进一步本文使用 U-Net 神经网络对二维角谱图像信号进行处理，实现了对涡旋光各阶角动量能量占比实现了精细识别。

第四章是对高维信号处理的神经网络设计，首先介绍模拟涡旋光通过大气湍流的方法，而后介绍本文提出的多维信息协助神经网络识别的方法，同时利用光强与角谱信息进行涡旋光模式识别。

最后结论部分为本文结束语总结本文工作。

第2章 一维光子计数激光探测信号处理方法研究

机器学习作为人工智能领域中发展最迅速的分支之一，如今已经被广泛应用于各个领域，比如计算机视觉，自然语言处理，语音识别。机器学习的飞速发展完全改变了人们的学习、工作和生活方式。以机器学习为主的各种统计学方法如今已经被广泛地应用于物理研究^[24]，并取得了巨大的成果。机器学习如今发展出的成熟的算法如卷积神经网络^[25]，注意力机制^[26]等，能够应对各种复杂的问题。本文拟利用机器学习解决光学领域几个不同维度的复杂信号处理问题。其中对于一维的光子计数雷达信号，本文拟采用时序卷积神经网络来处理。

2.1 光子计数激光探测时序信号

图2-1到??为不同噪声率下光子计数激光探测时序信号。随着噪声的增强，当噪声率达到 3MHz 时，已经很难分辨出哪里信号的位置。这时，需要多次探测，大量探测信号叠加才能辨别出信号的位置。注意到激光探测时序信号的位置的信号只与其极小窗口内的信号是相关的，于是，激光探测时序信号的处理并不需要使用 self-attention，LSTM 等模型，直觉上讲，只需要关注信号位置临近的强度即可，于是本文拟采用时序卷积神经网络来处理光子计数激光探测信号。




图 2-1 噪声率为 1MHz 单次探测光子计数激光探测时序信号




图 2-2 噪声率为 1MHz 多次探测相加光子计数激光探测时序信号

2.2 时序卷积神经网络

如今，对于绝大多数时序数据的处理都采用的是循环神经网络的架构，比如 LSTM、GRU 等方法。但是，由于上述说明的光子计数激光探测信号的性质，




图 2-3 噪声率为 3MHz 单次探测光子计数激光探测时许信号




图 2-4 噪声率为 3MHz 多次探测相加光子计数激光探测时许信号




图 2-5 噪声率为 5MHz 单次探测光子计数激光探测时许信号




图 2-6 噪声率为 5MHz 多次探测相加光子计数激光探测时许信号

不妨采用时序卷积神经网络进行信号处理。




图 2-7 膨胀因果卷积




图 2-8 残差模块

时序卷积神经网络的因果卷积的特点是，从将来倒过去不存在信息泄漏，可以输入任意长度的序列，并将其映射成相同长度的输出序列^[27]。但是在本文中为了方便生成训练集训练便不妨使用相同长度的输入。同时通过“膨胀”，并加深网络深度，可以使得神经网络关注到更长的序列。其中膨胀卷积输入 $x \in \mathbb{R}$ 与滤波器 $f: 0, \dots, k-1 \rightarrow \mathbb{R}$ ，卷积序列 s 的膨胀卷积算子可以被定义为：

$$F(s) = (x *_d f)(s) = \sum_{i=0}^{k-1} f(i) \cdot \mathbf{x}_{s-d \cdot i} \quad (2-1)$$

其中 d 是膨胀因子, k 是滤波器大小, $s - di$ 代表过去的方向。因此, 扩张卷积等效于在每两个相邻的滤波器之间引入一个固定的步长。当 $d = 1$ 时, 扩张卷积即为常规卷积。而使用较大的扩张因子, 可使顶层的输出表示更大范围的输入, 从而有效地扩展了 ConvNet 的感受野。

时序卷积神经网络的残差模块利用了 ResNet 的思想^[28], 一方面在加深神经网络增大神经网络函数域的同时包含浅神经网络的函数域保证效果大多数情况下不会变差, 同时把梯度由相乘变为相加, 使得神经网络浅层的梯度不易消失。

使用时序卷积神经网络的好处有: 1) 相对于循环神经网络, TCN 可以并行进行计算, 训练或预测时可以直接输入整个序列, 2) 感受野大小可控, TCN 利用加深神经网络或者增大滤波器大小都可以增大感受野的大小, 3) 梯度稳定, 时序卷积神经网络的反响传播路径与序列时间方向不同, 另外 ResNet 的使用一定程度上也避免了梯度爆炸或者梯度消失的问题。4) 可变输入长度, 时序卷积神经网络的一维卷积使得输入的维数灵活, 对于任意长度的序列都可以处理。

2.3 TCN 处理过程及结果

对于回归问题常用的用来量化结果准确性的损失函数为平均二范数损失函数

$$l = \frac{1}{n} \sum (x_n - y_n)^2 \quad (2-2)$$

由于带有噪声的光子计数激光探测信号处理问题是一个十分困难的问题, 仅用一次探测的结果难以得到准确的结果。于是需要一次输入神经网络多次探测的结果。本文发现利用时序卷积神经网络仅仅需要 3 次探测的结果就能在强噪声中准确的找出信号的位置。对于噪声率为 1MHz、3MHz、5MHz、7MHz、9MHz 情形, 由黄明维师兄提供训练集为 5400 次探测。其中由 5000 次探测生成训练集, 由 400 次探测生成测试集。生成训练集或测试集的方法为: 生成随机数矩阵 M , M 的大小为 $m \times n$, 其中 m 为想要的训练集大小, n 为通道数目。随机数矩阵内随机数的含义为一次探测作为训练集输入的起始时间点。随后根据随机数矩阵内数字把每次探测截取的时间段写入文件。

由图2-9可以看出识别准确率会随着噪声的增大而降低, 随着输入通道数的增加, 识别的准确率会上升。当通道数为 3 时在噪声低于 7 时达到收敛。为了能够更细致地观察准确率变化, 如图2-10 为损失函数取对数后取相反数的结果。




图 2-9 输入不同通道数的神经网络识别结果随着噪声率变化曲线




图 2-10 输入不同通道数的神经网络识别结果负对数随着噪声率变化曲线




图 2-11 通道一信号真实位置与预测位置




图 2-12 通道二信号真实位置与预测位置




图 2-13 通道三信号真实位置与预测位置

可以更清晰地看出随着通道数的增大，准确率是不断增大的，通道数到 5 之后准确率就已经很高了。

为了更加直观地展示时序神经网络的识别结果，如图 2-11 到图 2-13 为一个三通道输入时序卷积神经网络处理时序信号的结果的例子，其中图中红色竖线为真实信号位置，绿线为预测信号位置。可以看出即使在强噪声下，时序卷积神经网络依然能够做到精确地判断信号位置。

2.4 本章小结

本章首先阐述了光子计数激光探测信号的特点。经过分析最终使用了时序卷积神经网络。随后介绍了时序卷积神经网络的架构以及其在时序信号处理方面的优势。最后展示了时序卷积神经网络处理光子计数激光探测的结果。结果表明时序卷积神经网络能够充分地提取时序信号中的特征并能够精确地确定信号的位置。

第3章 二维角谱图像信号处理方法研究

通过对数极坐标变换方法可以获得涡旋光的角谱图像，但是由于衍射等现象使得得到的角谱图像不够理想，难以获得准确的涡旋光各阶能量占比。于是本文提出利用 U-Net 来对角谱图像进行处理，从而获得更加准确的能量占比。

3.1 涡旋光背景知识

涡旋光理论主要有两种 Poynting 矢量方法与正则动量方法^[1]。本文将介绍的是 Poynting 矢量方法。

对于空间依赖波函数 u ，麦克斯韦方程组导出的波函数方程在近轴近似下，相对于 $k \frac{\partial u}{\partial z}$ 可以忽略 $\frac{\partial^2 u}{\partial^2 z}$ ；相对于 u 可以忽略 $\left| \frac{\partial u}{\partial z} \right|$ ，于是得到近轴波函数方程：

$$i \frac{\partial u}{\partial z} = -\frac{1}{2k} \left(\frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2} \right) u \quad (3-1)$$

于是对于矢量势 A （真空各向同性空间中经典电动力学下场强线性可叠，布希和普遍性，以近朝向 x 轴为例）可以得到：

$$A = \hat{x} u(x, y, z) \exp(ikz) \quad (3-2)$$

由此可以得到洛伦兹规范下的 B 与 E 。

进一步可以求出 Poynting 矢量的时间平均：（为了让形势更加优美保留 $\left| \frac{\partial u}{\partial z} \right|$ ）

$$\varepsilon_0 \langle E \times B \rangle = i w \frac{\varepsilon_0}{2} (u \nabla u^* - u^* \nabla u) + w k \varepsilon_0 |u|^2 \hat{z} \quad (3-3)$$

光的轨道角动量与自旋角动量是值得分开的，二者来源不同，前者来源于特殊的相位分布，后者来源于光子的内禀属性自旋（经典下体现为偏振），下面分开讨论。

对于轨道角动量，考虑波函数为 $u(r, \phi, z) = u_0(r, z) \exp(i l \phi)$ 的场（实际上此表达式已经足够普遍，即使有偏振也可以把偏振信息储存到复振幅 \tilde{u} ，在此，不妨暂且认为 u 是一个标量实函数），为了求出单个光子轨道角动量值：

$$\frac{J_z}{W} = \frac{\iint r dr d\phi (r \times \langle E \times B \rangle)_z}{c \iint r dr d\phi \langle E \times B \rangle_z} = \frac{l}{w} \quad (3-4)$$

对于自旋角动量 $A = (\alpha \hat{x} + \beta \hat{y}) u(x, y, z) \exp(ikz)$ ，同上经计算得：

$$\frac{J_z}{W} = \frac{\iint r dr d\phi (r \times \langle E \times B \rangle)_z}{c \iint r dr d\phi \langle E \times B \rangle_z} = \frac{\sigma}{w} \quad (3-5)$$

其中 $\sigma = i(\alpha\beta^* - \alpha^*\beta)$

拉盖尔高斯光束为较为常用的轨道角动量光束，本文中使用的涡旋光均为拉盖尔高斯光束。拉盖尔高斯光束的复振幅可以表示为：

$$u_0(r, \theta, z) = \frac{C_{lp}^{LG}}{\omega(z)} \left(\frac{\sqrt{2}r}{\omega(z)} \right)^{|l|} \exp\left(-\frac{r^2}{\omega^2(z)}\right) L_p^{|l|} \left(\frac{2r^2}{\omega^2(z)} \right) \times \exp\left(-ik\frac{r^2}{2R(z)}\right) \exp(-il\theta) \exp(-ikz) \exp(-i\psi(z)) \quad (3-6)$$

其中 $L_p^{|l|}$ 为拉盖尔多项式， $C_{lp}^{LG} = \sqrt{\frac{2p!}{\pi(p+|l|)!}}$ ， $w(z)$ 为在位置 z 处的光腰， $R(z)$ 为波前的曲率半径， $\psi(z)$ 为古伊相位。

3.2 涡旋光角谱

涡旋光的角谱能够在一张图像中形象的表示出各阶涡旋光角动量占比，2010 年 Berkhout 等人提出由经过对数极坐标变换后再进行相位补偿可以得到^[10]。如图3-1要对入射光实现对数极坐标变换，首先需要经过第一个空间光




图 3-1 基于对数极坐标变换获得角谱流程图

调制器进行变换，然后经过透镜进行傅里叶变换后经过第二个空间光调制器进行相位补偿，最后通过透镜进行傅里叶变换得到角谱图像。

如图3-1，利用第一个空间光调制器可以做到对数及坐标变换变换 $(x, y) \mapsto (u, v)$ 可以得到关于角谱的信息，其中

$$u = -a \ln(\sqrt{x^2 + y^2}/b), \quad v = a \arctan(y/x) \quad (3-7)$$

为得到坐标变换后的坐标。第一个坐标变换的空间光调制器的相位改变量为：

$$\phi_1(x, y) = \frac{2\pi a}{\lambda f} \left[y \arctan\left(\frac{y}{x}\right) - x \ln\left(\frac{\sqrt{x^2 + y^2}}{b}\right) + x \right] \quad (3-8)$$

第二个空间光调制器相位补偿屏的相位修正项为

$$\phi_2(u, v) = -\frac{2\pi ab}{\lambda f} \exp\left(-\frac{u}{a}\right) \cos\left(\frac{v}{a}\right) \quad (3-9)$$

其中 λ 为波长, a 与 b 为聚焦屏大小与聚焦位置相关的参数, 详细情况见参考文献。经过两个静态的光学元件及相应的透镜聚焦, 螺旋的相位结构便可以变成倾斜平面波的相位结构。再经过透镜聚焦, 就可以做到分离不同轨道角动量的分量。简洁起见, 设经过对数及坐标变换变换后的光场为




图 3-2 对数极坐标变换结果示意图

$$U_{out} = \hat{L}U_{in} \quad (3-10)$$

如图3-2所示，经过对数极坐标变换后，环形的光强图像展开成条形的角谱图像，角谱图中横向位置表示的是涡旋光阶数，即如图第四列，向t方向移动，涡旋光拓扑核数增大。

在此基础上 2013 年 Mirhossenini 提出了高分辨率对数极坐标变换获得角谱^[29]，但是该系统较为复杂，需要经过多个空间光调制器与透镜。本文要介绍的是 Chenhao Wan 等人实现的简洁高分辨率对数及坐标变换^[30]，即为图3-3所示系统。




图 3-3 对数极坐标变换简洁实现示意图

$$U_{out} = \hat{L}U_{in} \quad (3-11)$$

首先入射待测光经过第一个空间光调制器，即二次展开映射，其中相位屏相位为

$$\begin{aligned} \Psi_1(x, y) = & \underbrace{\frac{2\pi d}{\lambda f} \left(y \tan^{-1} \left(\frac{y}{x} \right) - \frac{x}{2} \ln(x^2 + y^2) + px \right)}_{\text{transformation term}} \\ & + \underbrace{\tan^{-1} \left(\frac{\sum_{m=-N}^N b_m \sin \left(\frac{2\pi\theta}{\lambda} my + a_m \right)}{\sum_{m=-N}^N b_m \cos \left(\frac{2\pi\theta}{\lambda} my + a_m \right)} \right)}_{\text{fan-out term}} - \underbrace{\frac{\pi}{\lambda f} (x^2 + y^2)}_{\text{lens term}} \end{aligned} \quad (3-12)$$

其次经过一倍焦距后再经过对偶相位补偿屏，其相位为

$$\Psi_2(x', y') = \sum_{m=-N}^N \left(-\frac{2\pi L \exp(p-1)}{\lambda f} \exp\left(-\frac{x'}{L}\right) \cos\left(\frac{y'}{L}\right) \text{rect}\left(\frac{y' - 2m\pi L}{2\pi L}\right) + \phi_{bc}(m) \right) \quad (3-13)$$

最后经过一倍焦距即可得到角谱图像，详细参数见参考文献^[30]。如图3-4所示高分辨率仿真与实验结果明显比图3-2所示的对数极坐标变换结果有更高分辨率。




图 3-4 基于对数极坐标变换获得角谱流程图

3.3 U-Net 网络架构

U-net 网络架构如图3-5所示^[31]。它由收缩路径（左侧）和扩展路径（右侧）组成。收缩路径遵循卷积网络的典型架构。它由两个 3x3 卷积（未填充卷积）的重复应用组成，每个卷积后面跟着一个整流线性单元 (ReLU) 和一个 2x2 最大池化操作，步幅为 2，用于下采样。在每个下采样步骤中，我们将特征通道的数量加倍。扩展路径中的每一步都包括对特征图进行上采样，然后将特征通道数量减半的 2x2 卷积（“上卷积”），与收缩路径中相应裁剪的特征图的连接，以及两个 3x3 卷积，每个后跟一个 ReLU。由于在每个卷积中都会丢失边界像素，因此裁剪是必要的。在最后一层，使用 1x1 卷积将每个 64 分量特征向量映射到所需数量的类。该网络总共有 23 个卷积层。为了允许输出分割图的无缝平铺，




图 3-5 U-net 网络架构

重要的是选择输入平铺大小，以便将所有 2x2 最大池化操作应用于具有偶数 x 和 y 大小的层。

3.4 U-Net 处理过程及结果

对于此问题同光子计数激光探测信号处理时采用的平均二范数损失来量化识别准确率。设 y_n 为监督学习第 n 个样品的标号， x_n 为第 n 个样品的预测值，则平均二范数损失为

$$l = \frac{1}{n} \sum (x_n - y_n)^2 \quad (3-14)$$

同时平均二范数损失事实上也是神经网络采用的损失函数。

当训练集大小为 70000 张图片时，预测的损失函数为 0.000458，可见实现了超精细识别。图3-6 为一个标签与预测值之间对比图。不难看出预测值与真实值之间非常接近。

如图3-7，例如当角动量为 1 的拉盖尔高斯光束通过对数极坐标变换与扇形展开后得到的角谱仅有 84.6% 的能量在角动量为 1 的范围内，而该角谱图像经过 U-net 后，有 99.6% 的能量在角动量为 1 的范围。对于不经过 U-Net 神经网络处理的角谱图像由于光的衍射等影响因素无法实现理想的对数及坐标变换，使得某一阶涡旋光难免会有分量弥散到其他阶上。有了 U-Net 神经网络提取特征，能够自动“学会”涡旋光在对数极坐标变换过程中是如何因为衍射等因素影响弥散到其他阶上的，来根据角谱图像能够“反推”涡旋光各阶能量占比。




图 3-6 U-net 识别结果与真实值关系

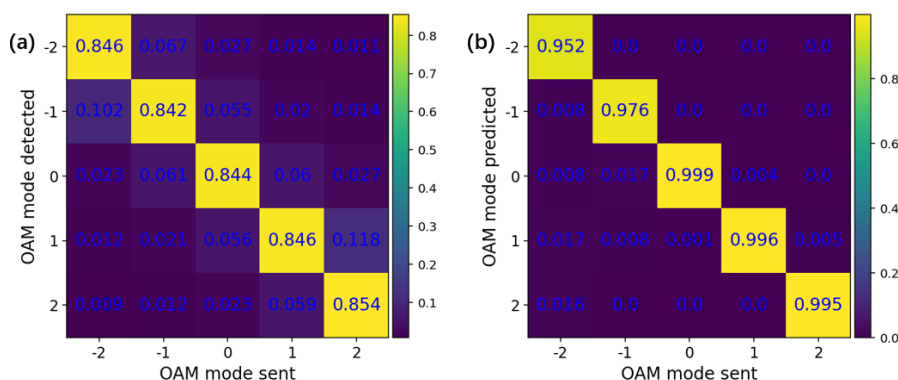


图 3-7 (a) 涡旋光角动量分别为-2 到 2，具有相同能量的涡旋光，经过对数极坐标变换与扇形展开后得到的各阶能量占比识别结果 (b) 涡旋光角动量分别为-2 到 2，具有相同能量的涡旋光，经过 U-net 预测后得到的能量占比识别结果

3.5 本章小结

本章首先简洁地介绍了涡旋光的背景知识。随后介绍了如今非常流行的涡旋光模式识别的方法，即对数极坐标变换获取涡旋光角谱。然后介绍了 U-Net 的网络架构。最后展示了通过 U-Net 能够更加精细的获取涡旋光各阶能量占比。

第4章 多维光强角谱图像融合信号处理方法研究

众所周知，光场是由一个复函数来描述的，仅仅给定光强是无法确定光场的，还需要相位才能完全确定。然而探测过程中，是无法用一张图片来确定一个复函数的，于是往往需要输入神经网络更多张图片。本文受多模态学习的启发，提出了多维信息融合神经网络来进行涡旋光模式的识别。

4.1 涡旋光通过大气湍流仿真

地球的大气介质的折射率是近乎为单位折射率的，这使得我们可以对真空的衍射传播进行一些近似来模拟光的传播。然而大气的折射随着光传播的时间空间变化是随机的。为了仿真光在大气湍流中的传播，前人提出了许多涡旋光通过大气湍流折射率的变化模型。在最近的一百年里，涌现了许多利用统计模拟的方式仿真大气湍流，因为准确预知所有时间段全部空间内的折射率的变化情况是不可能的。机器学习往往需要大量的训练集，在计算复杂度与仿真效果之间进行权衡后，本文拟采用 A.N.Kolmogorov 等人提出的湍流相位屏的方式仿真大气湍流生成训练集。

湍流相位屏仿真大气湍流是基于这样一个想法：仿真光在大气湍流中传播分为两个步骤，第一个步骤相当于光在真空中传播，第二个步骤为相位的随机变化。光在大气湍流中的光强与相位随机变化是由于随机的温度变化与大气运动所导致的。本文不作详细的理论推导与解释，详细的推导见参考文献^[32]。本文利用的模型是由 Hill 发展的^[33]，由 Andrews 进一步数值化^[34]。本文利用 modified von Karman 折射率功率谱密度： $\phi^2(\kappa) = 0.49r_0^{-5/3} \frac{\exp(-\kappa^2/\kappa_m^2)}{(\kappa^2 + \kappa_0^2)^{11/6}}$ ，其中 $r_0 = [0.423k^2 C_n^2 \Delta z]^{-3/5}$ 为湍流相干长度。 Δz 为相位屏之间的距离， C_n^2 大气湍流折射率结构常数，代表湍流强度。湍流相位屏的相位改变量为 $\theta(x, y) = FFT(M\phi(\kappa))$ 。其中 M 为一复随机矩阵，其中随机数实部与虚部均遵循均值为 0 方差为 1 的高斯分布。设 $H = \exp(ik\Delta z) \cdot \exp(-i(\kappa_x^2 + \kappa_y^2)\Delta z/2k)$ 表示菲涅耳衍射。则经过一次湍流相位屏的光场的复振幅为

$$U(z + \Delta z, x, y) = FFT^{-1}[H \cdot FFT[\exp(i\theta(x, y)) \times U(z, x, y)]] = \hat{T}U(z, x, y) \quad (4-1)$$




图 4-1 (a)(d) 为拓扑核数为通过大气湍流折射率结构常数 $C_n^2 = 10^{-14} m^{-2/3}$ 时大气湍流的光强图像。(b)(e) 为经过大气湍流的角谱图像。(c)(f) 为不经过大气湍流的角谱图像

4.2 多维特征融合神经网络

本文所使用的系统如图4-2所示激光器发射高斯光束，经过空间光调制器后转化为拉盖尔高斯光束。随后经过湍流相位屏模拟大气湍流后分成两部分，第一部分直接经 CCD 相机探测光强，第二部分经过对数极坐标变换后生成角谱图像，二者同时输入多维信息融合神经网络。不妨设经过大气湍流的光强图像为 $I_1(x, y)$ 如式 (4-2)。

$$I_1(x, y) = \left| \hat{T}^n U(z, x, y) \right|_{z=0}^2 \quad (4-2)$$

设经过大气湍流的角谱图像为 $I_2(x, y)$ 如式 (4-3)。

$$I_2(x, y) = \left| \hat{L} \hat{T}^n U(z, x, y) \right|_{z=0}^2 \quad (4-3)$$

在多维信息融合神经网络中，角谱与光强图像首先分别经过三层卷积神经网络，具体参数如图。随后经过卷积块注意力模型。卷积块注意力模型中首先经过通道注意力模块可以使得神经网络理解什么样的特征是重要的，其次经过空间注意力模块，使得神经网络理解重要的特征的位置^[35]。提取特征之后，把

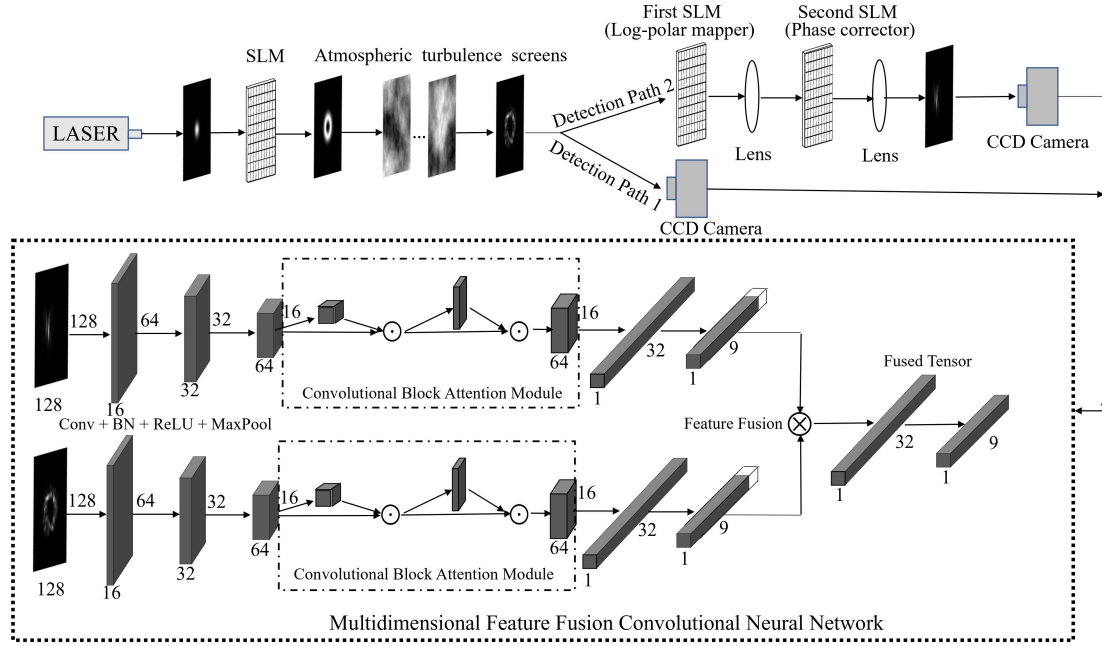


图 4-2 多维特征融合神经网络流程示意图

特征拉成一维的全连接层。补上一个为常量 1 的维度后，光强与角谱的特征 \mathbf{z}_1 与 \mathbf{z}_2 进行张量积融合如式 4-4。采用张量积是为了能够更好地融合两维特征^[36]。补上常量 1 是为了保留原来提取的特征的值。最后通过两个全连接层进行分类。

$$\mathbf{Z} = \begin{bmatrix} \mathbf{z}_1 \\ 1 \end{bmatrix} \otimes \begin{bmatrix} \mathbf{z}_2 \\ 1 \end{bmatrix} \quad (4-4)$$

这样的—个多维信息融合神经网络实际上是为了找这样一个映射：

$$\hat{y} = \arg \max f(I_1(x, y), I_2(x, y); W) \quad (4-5)$$

其中， \hat{l} 为多维神经网络预测的涡旋光拓扑核数大小； I_1 为涡旋光经过湍流之后的光强分布 $I_1(x, y) = |\hat{T}^n U_0(x, y)|^2$ ； I_2 为经过湍流之后的涡旋光经过 log-polar 变换后的光强分布 $I_2(x, y) = |\hat{L}\hat{T}^n U_0(x, y)|^2$ ； W 为多维神经网络的参数。 f 为神经网络所寻找的映射。

为了寻找到这样一个映射，需要定义损失函数来衡量预测标签与真实标签之间的差异，并通过梯度下降迭代更新 W 以最小化损失函数，使得多维神经网络预测的值更加准确，本文所用的损失函数为多分类问题中常用的交叉熵损失函数

$$L = \sum_{i=1}^M \sum_{c=0}^{N-1} -y_c^{(i)} \log p_c^{(i)} \quad (4-6)$$

其中, M 为样本容量, N 为训练集的拓扑核数总数, $y_c^{(i)}$ 为二值变量 (binary indicator), 其为 1 当且仅当第 i 个样本的实际拓扑核数大小为 c , $p_c^{(i)}$ 为神经网络预测第 i 个样本拓扑核数大小为 c 的概率。

4.3 多维特征融合神经网络处理过程及结果

本文产生训练集所用的 Δz 为 200m, 利用的激光波长为 532nm, 光腰 w_0 大小为 3cm, 生成湍流图像大小为 600×600 , 神经网络读取训练集前把图像 resize 到 128×128 个像素, 训练集的大小为每个模式 600 个图片, 测试集的大小为每个模式 200 个图片, Discussion 部分会有对训练集大小的讨论。本文产生训练集所用的 Δz 为 200m, 利用的激光波长为 532nm, 光腰 w_0 大小为 3cm。生成湍流图像大小为 600×600 。

4.3.1 距离限制

本文所提出的角谱与光强二维信息输入神经网络可以识别当激光发射端与接受端的距离发生变化时的涡旋光模式, 如图, 在大气湍流折射率结构常数为 $C_n^2 = 10^{-14} m^{-2/3}$ 时, 拓扑核数 $l = 1$ 到拓扑核数 $l = 9$ 经过大气湍流传播 1000m 的涡旋光作为训练集, 把传播不同距离的涡旋光分别作为测试集输入神经网络, 得到的结果如图4-3。

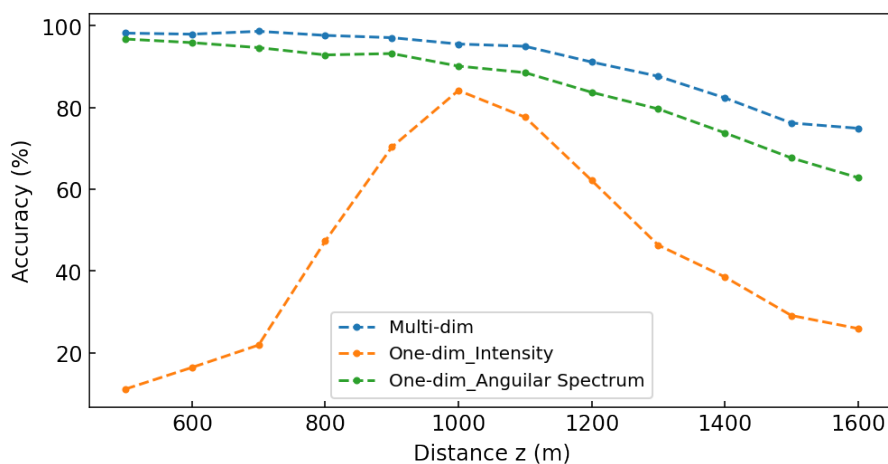


图 4-3 涡旋光在经过的大气湍流, 折射率结构常数为 $C_n^2 = 10^{-14} m^{-2/3}$ 时, 在大气湍流中传播 1000m 所得结果作为训练集, 测试集模式识别准确率随着距离变化的结果。

拉盖尔高斯光束的拓扑核数越大, 光腰越大, 这使得光腰大小成为卷积神经网络抽取的关键特征。然众所周知光在传播过程中光腰是自然增大的。于是以往只利用光强信息的神经网络难以识别传播不同距离的涡旋光模式。为了展示, 不同于传统的只利用光强信息的神经网络, 本文所提出的多维信息融合神




图 4-4 神经网络在测试集涡旋光传播 600m 时的具体识别情况。




图 4-5 神经网络在测试集涡旋光传播 1600m 时的具体识别情况。

神经网络能够实现准确率随着距离变化仍有鲁棒性，首先固定训练集的拉盖尔高斯光束的传播距离为 $1000m$ ，而采用不同传播距离的测试集，结果如图4-3。

正如图4-3所示，传统方法的准确率在训练集与测试集传播距离相同时达到顶峰，随着测试集传播距离的偏移，传统的一维光强识别涡旋光模式的方法的识别准确率迅速下降。然而，一维角谱识别与多维信息融合神经网络识别仍然有鲁棒性。这也说明了相位是涡旋光的更本质的特征。图4-4与图 4-4也进一步验证了以上的分析。当训练集的传播距离比测试集的距离大时，预测涡旋光模式会整体向拓扑核数较大的方向移动，因为随着传播距离的增加，涡旋光光强图像的环的宽度会不断增大，光强一维神经网络提取的很大一部分特征是光强环形图像的宽度。而训练集的传播距离比测试集较小时，按相同的道理，结果相反。

4.3.2 正负拓扑核数限制

众所周知有同样绝对值符号相反的拓扑核数的拉盖尔高斯光束有着相同的光强图像。这使得涡旋光模式的符号的识别仅凭光强是无法做到的，事实上以往并没有研究实现不同符号的涡旋光模式的识别。如图4-6，多维特征融合神经网络能够很好地实现不同符号的涡旋光模式的识别。其中热度图上热度几乎都在表示识别正确的对角线附近，拓扑核数相反的对角线上几乎没有热度。

另外，如图4-6也可以看出阶数越高的涡旋光角谱弥散的程度越大。随着拓扑核数的增大，非对角线的热度逐渐增大，即识别准确率会降低。这是由于随着拓扑核数的增大，角谱弥散的程度会更加严重，这与以往的研究是一致的^[37]。

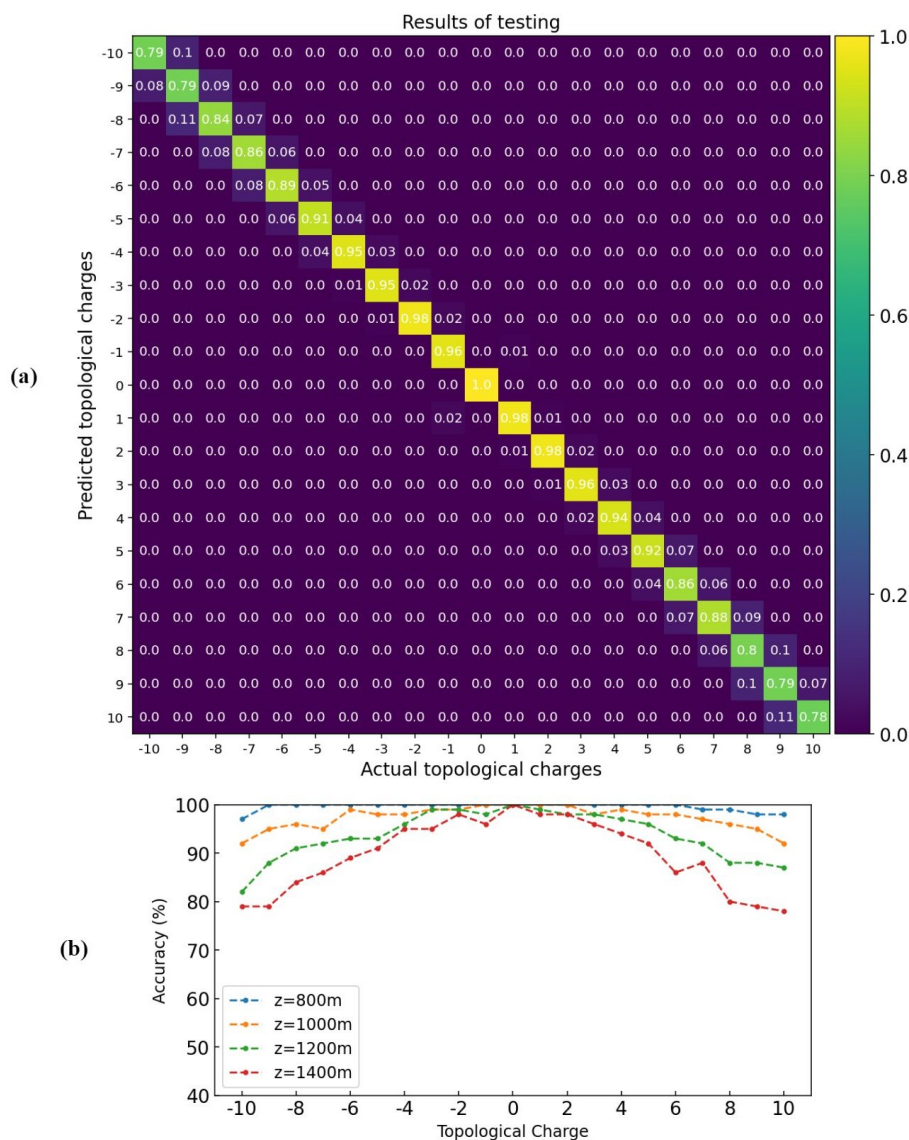


图 4-6 阶数为 $-6 \sim +6$ 的涡旋光在经过湍流折射率结构常数为 $C_n^2 = 10^{-14} m^{-2/3}$ 的大气湍流时，涡旋光模式识别准确率

4.3.3 湍流强度

如图4-7所示，随着湍流强度的增强，传统的光强一维识别在湍流折射率结构常数为 $C_n^2 = 10^{-15} m^{-2/3}$ 之后就开始迅速下降，对于角谱一维识别在湍流折射率结构常数为 $C_n^2 = 4 \times 10^{-15} m^{-2/3}$ 时也开始逐渐下降。这说明角谱一维识别也是一个比较可靠的识别方法。这是因为如图4-1所示，经过大气湍流后角谱的弥散是对称的，使得角谱识别依然比较可靠。本文提出的多维信息融合神经网络的识别准确率即使湍流强度达到 $C_n^2 = 7 \times 10^{-15} m^{-2/3}$ ，仍然能够保持 97.9% 的识别准确率。光强与角谱的信息可以在多维信息融合神经网络中互相补充使得识别准确率都能够比一维的识别准确率更高。

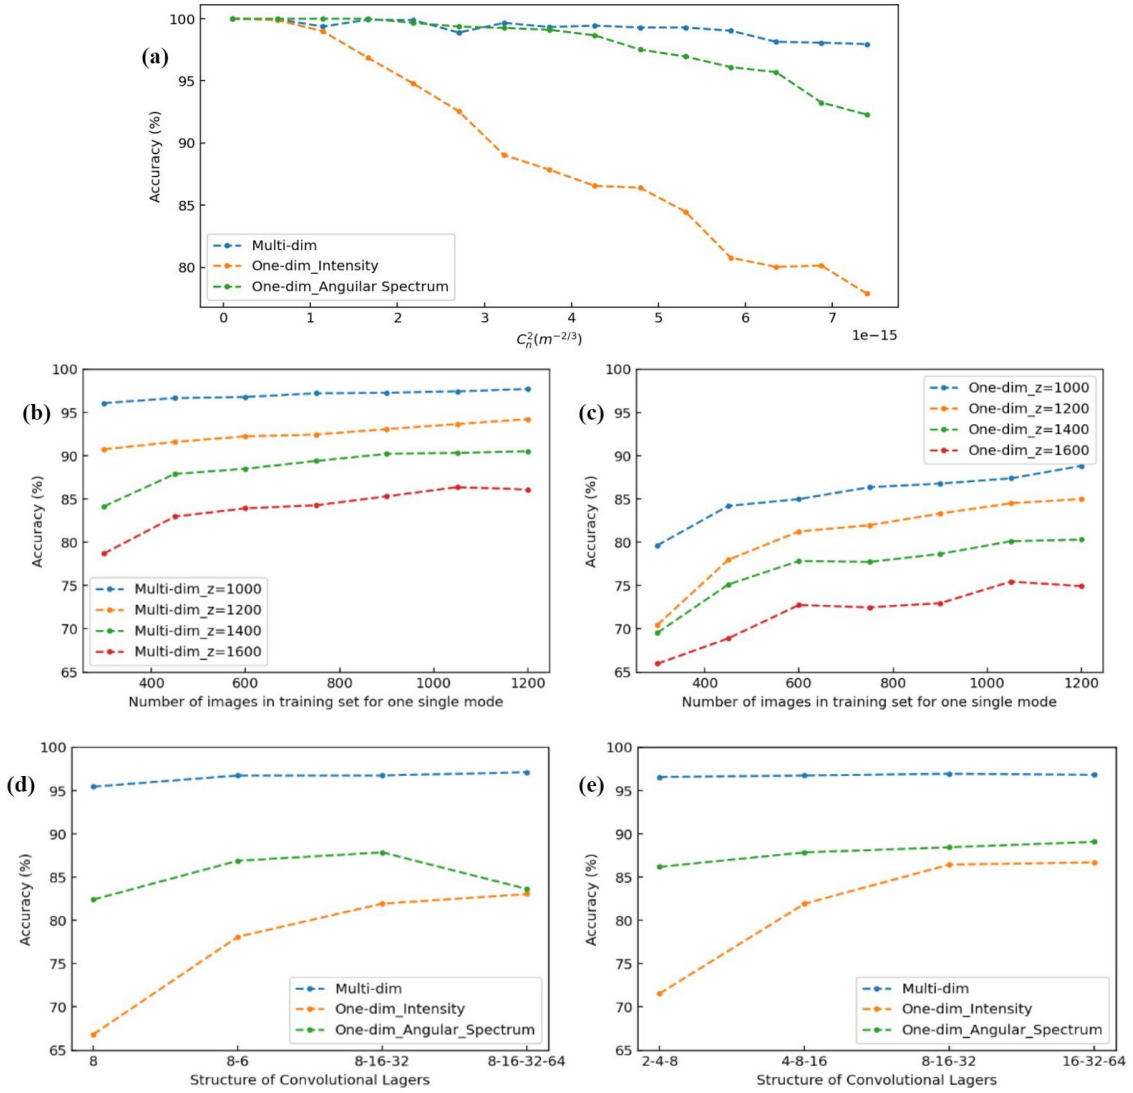


图 4-7 (a) 涡旋光通过 1000m 不同强度的大气湍流后涡旋光模式识别准确率变化曲线。(b) 本文的多维信息融合神经网络在不同传播距离下，识别准确率，随着训练集大小，识别准确率变化曲线。(c) 传统光强一维识别不同传播距离下，识别准确率随着训练集大小变化，识别准确率变化曲线。大气湍流折射率结构常数为 $C_n^2 = 10^{-14} m^{-2/3}$ 。(d)(e) 为多维信息融合神经网络与角谱一维识别、光强一维识别，随着神经网络复杂度变化的识别准确率变化曲线。其中横坐标如“2-4-8”表示的是卷积神经网络有三层，通道数分别为 2，4，8。大气湍流折射率结构常数为 $C_n^2 = 10^{-14} m^{-2/3}$ 。

4.3.4 训练集大小

众所周知，更大的训练集往往使得准确率在某一上界之下逐渐增大。然而生成或者获取训练集往往计算量比较大或者是十分昂贵的。于是我们往往需要对训练集大小作权衡。大多数情况下随着训练集大小的增大，在某一大小之后准确率几乎不再上升。我们不妨在本文称这一点的大小为收敛点。

如图4-7所示，在大气湍流中传播距离越长，往往需要更大的训练集。当涡旋光传播 1000m 或 1200m，对于本文提出的多维信息融合神经网络收敛点为每

个模式 300 张图片。同时对于传播距离为 1400m 或 1600m 的收敛点为 600 与 750 张图片每个模式。然而对于传统的光强一维识别的神经网络所需要训练集大小为 600 张图片每个模式对于传播距离为 1000m 的情况。总之，对于本文提出的多维信息融合神经网络所需的训练集要比光强一维识别所需的训练集要小往往一倍。

4.3.5 计算复杂度

如图4-7所示，多维信息融合神经网络不需要太复杂的卷积神经网络就可以达到很高的识别准确率。比如，当只有一层卷基层时即可达到 95% 的识别准确率，而此时的一维光强识别准确率仅为 66.7%。同时也可以看出一维神经网络需要三层卷基层才能到达收敛的效果且收敛时的识别准确率要远远低于多维信息融合神经网络。我们不妨用最常用的浮点运算次数 (FLOPs) 来衡量计算复杂度^[38]。对于一维神经网络识别准确率收敛时 FLOPs 为 13.9MFLOPs，而对于多维信息融合神经网络收敛所需要的计算复杂度仅为 6.17MFLOPs。我认为出现这种情况的原因为来自光强的特征能与来自角谱的特征互相补充。然而角谱来的特征不需要很复杂的卷积神经网络即可提取出，这也验证了前文所提到的，角谱能够更加本质与直观的反映涡旋光的特征。

4.4 本章小结

本章首先介绍了涡旋光通过大气湍流的仿真方法。随后介绍了本文提出的多维特征融合神经网络。最后介绍了多维特征融合神经网络进行涡旋光模式识别的好处、结果。结果显示相比于传统的使用光强一维进行模式识别，多维特征融合神经网络能够突破距离限制，能够突破正负拓扑核数的限制，对于强湍流的识别更鲁棒，所需的训练集大小也显著更小，计算复杂度明显更低。

结 论

本文一共实现了三种处理光学信号的神经网络，分别能够处理一维时序信号处理，二维图像信号与更高维信号处理。光子计数雷达在探测远程目标时，如今的降噪手段鲁棒性仍然不够好。本文利用时序卷积神经网络能够很好地实现强噪声下的目标探测。由于涡旋光角动量可以取任意整数值，可以构成一无穷维向量空间，理论上有无数的信息容量，涡旋光近几年在光学通信领域吸引了很多注意。本文提出利用 U-Net 来更精确地识别角谱信号，更精确地识别各阶角动量能量占比。最后第一次提出了一种多维特征融合神经网络能够同时利用光强与角谱信息识别通过大气湍流的涡旋光模式。

首先本文提出的时序卷积神经网络能够通过更少的样本，在强噪声下实现精确的信号识别。其中，即使对于噪声率为 9M 的信号，在 5 个样本的识别时，损失函数仅为 0.00591。在利用五个样本进行识别，噪声率小于 7M 时，损失函数均小于 0.0001。

其次本文在简要介绍涡旋光基本背景与角谱基本知识后，提出了利用 U-Net 进行角谱信号的处理。利用 U-Net 处理角谱图像后，能够实现更精细地识别涡旋光在各阶的能量占比。比如，对于纯阶能量占比识别，识别能量占比高于 95%。

最后，本文提出了多维特征融合神经网络，利用了卷积块注意力模型与张量积融合，能够实现更高维度的信号处理。利用多维特征融合神经网络能够突破传统方法的距离限制与正负拓扑核数限制。另外能够显著减小所需要的训练集大小与计算复杂度。

参考文献

- [1] Padgett M J. Orbital angular momentum 25 years on [Invited][J]. Optics Express, 2017, 25(10): 11265-11274.
- [2] Allen L, Beijersbergen M W, Spreeuw R J C, et al. Orbital angular momentum of light and the transformation of Laguerre-Gaussian laser modes[J]. Physical Review A, 1992, 45(11): 8185-8189.
- [3] Paterson L, MacDonald M P, Arlt J, et al. Controlled Rotation of Optically Trapped Microscopic Particles[J]. Science, 2001, 292(5518): 912-914.
- [4] Jack B, Leach J, Romero J, et al. Holographic ghost imaging and the violation of a Bell inequality[J]. Physical Review Letters, 2009, 103(8): 083602.
- [5] Paterson C. Atmospheric Turbulence and Orbital Angular Momentum of Single Photons for Optical Communication[J]. Physical Review Letters, 2005, 94(15): 153901.
- [6] McCarthy A, Collins R J, Krichel N J, et al. Long-range time-of-flight scanning sensor based on high-speed time-correlated single-photon counting[J]. Applied Optics, 2009, 48(32): 6241-6251.
- [7] Wang F, Zhao Y, Zhang Y, et al. Range accuracy limitation of pulse ranging systems based on Geiger mode single-photon detectors[J]. Applied Optics, 2010, 49(29): 5561-5566.
- [8] Mair A, Vaziri A, Weihs G, et al. Entanglement of Orbital Angular Momentum States of Photons[J]. Nature, 2001, 412(6844): 313-316.
- [9] Leach J, Courtial J, Skeldon K, et al. Interferometric Methods to Measure Orbital and Spin, or the Total Angular Momentum of a Single Photon[J]. Physical Review Letters, 2004, 92(1): 013601.
- [10] Berkhout G C G, Lavery M P J, Courtial J, et al. Efficient Sorting of Orbital Angular Momentum States of Light[J]. Physical Review Letters, 2010, 105(15): 153601.
- [11] Knutson E M, Lohani S, Danaci O, et al. Deep learning as a tool to distinguish between high orbital angular momentum optical modes[C] // Optics and Photonics for Information Processing X: Vol 9970. [S.l.]: International Society for Optics and Photonics, 2016: 997013.

- [12] Liu J, Wang P, Zhang X, et al. Deep learning based atmospheric turbulence compensation for orbital angular momentum beam distortion and communication[J]. Optics Express, 2019, 27(12): 16671-16688.
- [13] Li J, Zhang M, Wang D, et al. Joint atmospheric turbulence detection and adaptive demodulation technique using the CNN for the OAM-FSO communication[J]. Optics Express, 2018, 26(8): 10494-10508.
- [14] Wang Z, Dedo M I, Guo K, et al. Efficient Recognition of the Propagated Orbital Angular Momentum Modes in Turbulences With the Convolutional Neural Network[J]. IEEE Photonics Journal, 2019, 11(3): 1-14.
- [15] Liu Z, Yan S, Liu H, et al. Superhigh-Resolution Recognition of Optical Vortex Modes Assisted by a Deep-Learning Method[J]. Physical Review Letters, 2019, 123(18): 183902.
- [16] Kucharski D, Kirchner G, Otsubo T, et al. A method to calculate zero-signature satellite laser ranging normal points for millimeter geodesy - a case study with Ajisai[J]. Earth, Planets and Space, 2015, 67(1): 34.
- [17] Fouche D G. Detection and false-alarm probabilities for laser radars that use Geiger-mode detectors[J]. Applied Optics, 2003, 42(27): 5388-5398.
- [18] Zhang Z, Zhao Y, Zhang Y, et al. A real-time noise filtering strategy for photon counting 3D imaging lidar[J]. Optics Express, 2013, 21(8): 9247-9254.
- [19] Rapp J, Goyal V K. A Few Photons Among Many: Unmixing Signal and Noise for Photon-Efficient Active Imaging[J]. IEEE Transactions on Computational Imaging, 2017, 3(3): 445-459.
- [20] Hua K, Liu B, Chen Z, et al. Efficient and Noise Robust Photon-Counting Imaging with First Signal Photon Unit Method[J]. Photonics, 2021, 8(6): 229.
- [21] Maccarone A, McCarthy A, Ren X, et al. Underwater depth imaging using time-correlated single-photon counting[J]. Optics Express, 2015, 23(26): 33911-33926.
- [22] Wallace EURASIP Member A M, Ye EURASIP Member J, Krichel N J, et al. Full Waveform Analysis for Long-Range 3D Imaging Laser Radar[J]. EURASIP Journal on Advances in Signal Processing, 2010, 2010(1): 1-12.
- [23] Xie D, Wang F, Chen J. Extended Target Echo Detection Based on KLD and Wigner Matrices[J]. Sensors, 2019, 19(24): 5385.
- [24] Breuer H-P, Laine E-M, Piilo J, et al. Colloquium: Non-Markovian dynamics in open quantum systems[J]. Reviews of Modern Physics, 2016, 88(2): 021002.

- [25] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [26] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[J]. arXiv:1706.03762 [cs], 2017.
- [27] Bai S, Kolter J Z, Koltun V. An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling[J]. arXiv:1803.01271 [cs], 2018.
- [28] Sheikh M. Spatial optical mode decomposition using deep learning[C] // Applications of Machine Learning 2020: Vol 11511. [S.l.]: International Society for Optics and Photonics, 2020: 115110M.
- [29] Mirhosseini M, Malik M, Shi Z, et al. Efficient separation of the orbital angular momentum eigenstates of light[J]. Nature Communications, 2013, 4(1): 2781.
- [30] Wan C, Chen J, Zhan Q. Compact and high-resolution optical orbital angular momentum sorter[J]. APL Photonics, 2017, 2(3): 031302.
- [31] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation[C] // Navab N, Hornegger J, Wells W M, et al. Lecture Notes in Computer Science: Medical Image Computing and Computer-Assisted Intervention –MICCAI 2015. Cham: Springer International Publishing, 2015: 234-241.
- [32] Andrews L, Phillips R. Laser Beam Propagation through Random Media[M]. [S.l.]: SPIE, 2005.
- [33] Hill R J. Models of the scalar spectrum for turbulent advection[J]. Journal of Fluid Mechanics, 1978, 88(3): 541-562.
- [34] Andrews L C, Vester S, Richardson C E. Analytic Expressions for the Wave Structure Function Based on a Bump Spectral Model for Refractive Index Fluctuations[J]. Journal of Modern Optics, 1993, 40(5): 931-938.
- [35] Woo S, Park J, Lee J-Y, et al. CBAM: Convolutional Block Attention Module[G] // Ferrari V, Hebert M, Sminchisescu C, et al. Computer Vision –ECCV 2018: Vol 11211. Cham: Springer International Publishing, 2018: 3-19.
- [36] Zadeh A, Chen M, Poria S, et al. Tensor Fusion Network for Multimodal Sentiment Analysis[J]. arXiv:1707.07250 [cs], 2017.
- [37] Anguita J A, Neifeld M A, Vasic B V. Turbulence-induced channel crosstalk in an orbital angular momentum-multiplexed free-space optical link[J]. Applied Optics, 2008, 47(13): 2414-2429.

- [38] Molchanov P, Tyree S, Karras T, et al. Pruning Convolutional Neural Networks for Resource Efficient Inference[J]. arXiv:1611.06440 [cs, stat], 2017.

哈尔滨工业大学本科毕业设计（论文）原创性声明

本人郑重声明：在哈尔滨工业大学攻读学士学位期间，所提交的毕业设计（论文）《基于机器学习的多维信号处理方法研究》，是本人在导师指导下独立进行研究工作所取得的成果。对本文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明，其它未注明部分不包含他人已发表或撰写过的研究成果，不存在购买、由他人代写、剽窃和伪造数据等作假行为。

本人愿为此声明承担法律责任。

作者签名：

日期： 年 月 日

致 谢

本文的研究工作是在许多人的指导与支持下完成的，首先要感谢张子静老师对我课题的谆谆教诲。张老师从大一作为班主任开始就积极鞭策与指导我不断学习，指导我完成了难忘的第一篇 SCI 文章写作。在研究过程中耐心指出我的错误并指正，在迷茫的时候也给予了我很多支持与鼓励。

感谢光电信技术研究所的岑龙柱师兄，黄明维师兄对我的研究的支持。岑龙柱师兄在光学仿真方面给了我很多宝贵的建议与支持，也在投稿过程中给了很多建议与指导。黄明维师兄在光子计数雷达方面给了我很多指导，也提供了实验结果作为数据集。

感谢中国农业大学的高中同学李一鸣同学提供机器学习相关指导，感谢本校的高中同学黄鹤鸣同学在物理学习过程中的讨论与陪伴，感谢酥酥老师的指导鼓励与支持。

感谢我的家人二十多年来的养育与支持鼓励，为我提供了宽容舒适的发展空间。

最后感谢我的女朋友在我人生的前 22 年没有出现，使得我能够专注学业。